Detektor fake newsów z użyciem LLM

Projekt 2 – Wyjaśnialne systemy oparte na LLM

Karolina Gralak
Wiktor Chmiel

2026

Cel projektu

- Zbudować system, który klasyfikuje krótkie newsy / posty
- Klasyfikacja twierdzeń na:
  - Prawda
  - Fałsz
  - Manipulacja
  - Nieweryfikowalne
  - Odrzucone
- Wyjaśnialność decyzji modelu

Baza wiedzy i dane testowe

- Lokalna baza wiedzy z wielu domen:
  - Gospodarka
  - Polityka i historia
  - Sport
  - Technologia / YouTube
  - Nauka i zdrowie
  - Jedzenie
- ponad 70 przykładowych zapytań

Jak działa model?

Scenariusz: Użytkownik wpisuje: *"Inflacja w Polsce wynosi 20%."*

1. **Analiza Intencji:** Model sprawdza, czy jest to twierdzenie do weryfikacji. Jeśli to pytanie otwarte to proces jest przerywany
2. **Wyszukiwanie:** Moduł `DuckDuckGo` szuka fraz: *"inflacja Polska GUS"*.
3. **Generowanie:** LLM otrzymuje fragmenty artykułów i tworzy wstępny werdykt.
4. **Korekta:** Model następnie sprawdza draft pod kątem błędów logicznych i generuje finalne uzasadnienie
5. **Weryfikacja Cytowań (XAI):** Biblioteka `RapidFuzz` porównuje tekst modelu z tekstem źródłowym, obliczając **Grounding Score**

Wynik dla użytkownika

Werdykt: FAŁSZ + Uzasadnienie + Linki do źródeł + Pasek wiarygodności.

Krok 1: Weryfikacja Intencji

Cel modelu: Odrzucenie wszystkich możliwych scenariuszy, które niespełniają założenia. Od razu przyspiesza to sam proces przetwarzania prompta

Jak to działa?

Zanim system zacznie szukać w Internecie, szybki klasyfikator LLM ocenia wejście:

- Czy to zdanie oznajmujące?
- Czy zawiera weryfikowalny fakt?

*Jeśli odpowiedź brzmi **NIE** to zapytanie jest przerwane*

Przykłady:

Wejście zaakceptowane

"Bezrobocie w Polsce spadło poniżej 6%."

Status: **Twierdzenie** → **Przechodzimy dalej**

Wejście odrzucone

"Opowiedz mi żart o programistach."

Status: **Chitchat/Inne** → **Stop**

Krok 2: Pobieranie Dowodów Z Internetu

Wyzwanie: Modele lokalne posiadają "zamrożoną wiedzę". Nie wiedzą, co wydarzyło się wczoraj

Rozwiązanie: Live Search

Model wykorzystuje bibliotekę `duckduckgo-search`, aby douczyć model w czasie rzeczywistym

Proces:

1. Znalezieni słów kluczowych
2. Wysłanie zapytania do API
3. Pobranie $k = 5$ najlepszych fragmentów

Przykład:

1. Zapytanie

`"bezrobocie Polska GUS styczeń 2024"`

↓

2. Pobrany Kontekst

[Wynik 1]: Business Insider: "GUS podał najnowsze dane. Stopa bezrobocia w styczniu 2024 wyniosła 5,4%..."

[Wynik 2]: Gov.pl: "Rynek pracy pozostaje stabilny, odnotowano niewielki spadek..."

Krok 3 i 4: Klasyfikacja i Weryfikacja

Po pobraniu dowodów, model przystępuje do dalszej analizy w dwóch warstwach:

1. Warstwa Logiczna)

Zamiast generować prostą odpowiedź, model wykonuje proces **Self-Correction**:

- **Szkic:** Model generuje wstępną ocenę na podstawie kontekstu
- **Krytyka:** Model sprawdza samego siebi"– szuka błędów logicznych w szkicu i koryguje ostateczny werdykt

2. Warstwa Weryfikacyjna

Dalej stosownay jest algorytm **RapidFuzz**:

1. Wyciągamy cytaty, którymi model podpiera swoją tezę
2. Porównujemy je znak po znaku z oryginałem
3. Jeśli podobieństwo jest niższe niż **75%** to cytat jest odrzucany

Krok 5 - Wyjaśnialność Decyzji (XAI)

Model oferuje 3 poziomy wyjaśnialności:

1. Uzasadnienie Językowe

Model nie zwraca samej etykiety (np. "Fałsz"), ale generuje **opis** przyczyn swojej decyzji, wskazując na rozbieżności między twierdzeniem a znalezionymi faktami

2. Źródła

Każda odpowiedź zawiera listę **linków** lub fragmentów tekstu, z których model korzystał Możemy samodzielnie sprawdzić źródło

3. Grounding Score

System oblicza matematyczny wskaźnik wiarygodności (0-100%):

- **Jak to działa?** Algorytm sprawdza, czy cytaty podane przez model *rzeczywiście* istnieją w pobranych artykułach.
- **Cel:** Wykrywanie halucynacji, czyli sytuacji gdy model zmyśla cytaty

Przykłady zastosowań- zdania fałszywe

AI FACT-CHECKER ✕ FAŁSZ

ANALIZOWANE WEJŚCIE

"Unia Europejska nakazała konfiskatę wszystkich samochodów spalinowych w Polsce do końca tego roku, bo wszedł zakaz na takowe pokjazdy"

1. Wstępna analiza: Z podanych faktów nie wynika, że Unia Europejska nakazała konfiskatę wszystkich samochodów spalinowych w Polsce ani wprowadziła zakaz ich użytkowania do końca roku. Nie ma żadnego wymienionego aktu prawnego lub dyrektywy UE dotyczącej takiego zakazu. Dlatego twierdzenie jest nieprawdziwe.

2. Werdykt po krytyce: The provided evidence shows that the European Union has not imposed a confiscation of all combustion-engine cars in Poland nor banned their use until the end of this year. The EU's policy focuses on phasing out new sales of combustion vehicles after 2035 and reducing CO2 emissions, but it explicitly allows existing vehicles to continue operating. No legal act or directive mandates confiscation or an immediate ban in Poland.

Wiarygodność Cytowań (XAI): 0%

PL **PODSUMOWANIE**

Unia Europejska nie nakazała konfiskaty wszystkich samochodów spalinowych w Polsce ani zakazu ich użytkowania do końca roku; istniejące pojazdy mogą nadal być używane, a regulacje dotyczą jedynie nowych sprzedaży po 2035 r.

DOWODY (LIVE SEARCH):

Komisja Europejska rezygnuje z zakazu aut spalinowych po 2035 roku: December 18, 2025 - Komisja Europejska wycofuje się z planu całkowitego zakazu sprzedaży nowych samochodów spalinowych w Unii Europe...

Unijny zakaz sprzedaży nowych samochodów spalinowych od 2035 r. - co to oznacza? | Tematy | Parlament Europejski: March 7, 2023 - Tak, nadal będzie można jeździć obecnymi samochodami. Nowe przepisy ni...

Komisja Europejska podjęła ważną decyzję dla całej motoryzacji. Co to oznacza dla klientów?: December 17, 2025 - Kiedy w marcu 2023 r. zapadła decyzja o zakazie sprzedaży aut spalinowych na terenie UE...

Unia wycofa się z zakazu aut spalinowych od 2035? Urzędnik KE nie ma wątpliwości: September 28, 2024 - Transport stał się ofiarą własnego sukcesu - stwierdził Eddy Liegeois z Komisji Europejskiej. Pod...

Koniec Aut Spalinowych. Od Kiedy Zakaz Sprzedaży? - Elektromobilni.pl: January 24, 2024 - Unia Europejska zobowiązała się do przedstawienia w 2026 roku raportu dotyczącego wprowadzonych przepisów....

AI FACT-CHECKER ✕ FAŁSZ

ANALIZOWANE WEJŚCIE

"Karolina Gralak jest najszybszym człowiekiem na świecie."

1. Wstępna analiza: Z podanych faktów wynika, że najszybszym człowiekiem na świecie jest Usain Bolt, a nie Karolina Gralak.

2. Werdykt po krytyce: Karolina Gralak nie jest najszybszym człowiekiem na świecie; rekord 100 m utrzymuje Usain Bolt z wynikiem 9,58 s w Berlinie 2009. Brak dowodów wskazujących, że Gralak osiągnęła lepszą prędkość niż Bolt.

Wiarygodność Cytowań (XAI): 50%

PL **PODSUMOWANIE**

Karolina Gralak nie jest najszybszym człowiekiem na świecie – rekord 100 m należy do Usaina Bolta. Dowody z podanych źródeł potwierdzają, że Bolt ustanowił najwyższy czas w sprincie. Nie ma żadnych wiarygodnych danych sugerujących, że Gralak przewyższa jego wynik.

DOWODY (LIVE SEARCH):

Kto jest najszybszym człowiekiem na świecie? To nazwisko nigdy nie ...: Na dystansie 100 metrów osiągał prędkość w granicach 43-45 km/h. Do pokonania tego dystansu potrzebował zaledwie 40 do 42. krokó...

Kto jest najszybszym człowiekiem na świecie? - Sport: Jednak pytanie, czy jest on najszybszym człowiekiem w historii, jest bardziej złożone, niż mogłoby się wydawać. O ile rekord Bolta jest niepodważa...

Najszybszy człowiek na świecie - ICHI.PRO: Kiedy oglądasz najlepszych wykonawców na ś wiecie , wygląda to tak łatwo i naturalnie. Ale powodem, dla którego wydaje się to łatwe, jest cała ciężka praca, ...

Oto najszybszy człowiek na świecie! Wygrał złoto o 0,005 sekundy: Aktualny mistrz świata zaczął wysuwać się minimalnie na prowadzenie. Na metę wszyscy wpadli niemalże w tym samym momencie....

Najszybszy człowiek świata - rekordy prędkości, fakty: Jak dotąd jest najszybszym człowiekiem , który ustanowił rekord świata w sprincie na 100 m (osiągnięty w Berlinie w 2009 roku, pobijając swój pop...

Przykłady zastosowań- zdania nieweryfikowalne

AI FACT-CHECKER

❓ NIEWERYFIKOWALNE

ANALIZOWANE WEJŚCIE

"W 2040 roku prezydentem Polski zostanie kobieta o imieniu Anna."

1. Wstępna analiza: Brak informacji w podanej bazie wiedzy dotyczącej przyszłych wyborów prezydenckich ani o osobach, które mogłyby objąć urząd w 2040 roku. Stwierdzenie dotyczy zdarzenia z przyszłości i nie można go potwierdzić ani obalić na podstawie dostępnych faktów.

2. Werdykt po krytyce: The claim concerns a future political event (the presidency of Poland in 2040) and there is no verifiable evidence or reliable source confirming that a woman named Anna will hold the office at that time. The provided references discuss individuals named Anna, a person called Mata expressing ambitions for the presidency, and general information about names, but none provide factual confirmation of an election outcome in 2040. Therefore the statement cannot be verified as true or false based on current knowledge.

Wiarygodność Cytowań (XAI): 100%

PL **PODSUMOWANIE**

Twierdzenie dotyczy przyszłego wydarzenia politycznego i nie ma dostępnych wiarygodnych dowodów potwierdzających lub obalających, że w 2040 roku prezydentem Polski będzie kobieta o imieniu Anna. Stąd jest nieweryfikowalne.

DOWODY (LIVE SEARCH):

Znaczenie imienia Anna . Skąd pochodzi, kiedy są... | Strona Kobiet: Znaczenie imienia Anna może wiele powiedzieć o osobach, które tak nazwano. Przede wszystkim są to kobiety inteligentne, empatyczne ...

2040 Mata Tekst | TikTok: Mata chce zostać Prezydentem Polski w 2040 roku . #mata #michałmatczak #michałmatamatczak #420 #fundacja420 #mata 2040 # prezydent # polska . Prezydent Mata o "imprezie masow...

Anna , która bada Bałtyk: Anna , która bada Bałtyk. poniedziałek, 17 kwietnia 2023. Informacja prasowa/Equinor.pl.- Badania wietrzności to ważny krok w realizacji morskiej farmy wiatrowej Bałtyk I, kt...

Mata chce zostać prezydentem ? "Nie do wiary, że ludzie tak na serio..."...: - Oficjalnie rozpoczynam moją kampanię na urząd prezydenta Rzeczpospolitej Polskiej w 2040 r. - zapowiedział w najnowszym n...

Kim jest Anna ? Dowiedz się o niej więcej! - Prezydent internetu: Kobieta : Anna jest kobietą o imieniu Anna . Anna jest osobą, która od najmłodszych lat wykazywała się niezwykłą determinacją i pasją ...

AI FACT-CHECKER

❓ NIEWERYFIKOWALNE

ANALIZOWANE WEJŚCIE

"Zupa pomidorowa jest obiektywnie najsmaczniejszą zupą na świecie."

1. Wstępna analiza: Brak informacji w podanej bazie wiedzy dotyczącej subiektywnego smaku zupy pomidorowej ani żadnych danych porównujących jej smak do innych zup. W związku z tym nie można potwierdzić ani obalić twierdzenia, a jedynie stwierdzić, że jest ono nieweryfikowalne na podstawie dostępnych faktów.

2. Werdykt po krytyce: The statement "Zupa pomidorowa jest obiektywnie najsmaczniejszą zupą na świecie" is a subjective claim about taste, which cannot be objectively verified or falsified with the provided evidence. The evidence consists of anecdotal descriptions and personal opinions that praise tomato soup but do not provide comparative data or objective measures of flavor superiority over other soups.

Wiarygodność Cytowań (XAI): 100%

PL **PODSUMOWANIE**

Twierdzenie jest subiektywne i nie podlega obiektywnej weryfikacji; brak dowodów porównawczych ani mierzalnych kryteriów smaku, więc uznajemy je za nieweryfikowalne.

DOWODY (LIVE SEARCH):

Zupa pomidorowa ze świeżych pomidorów będzie najsmaczniejsza ...: Zupa pomidorowa jest najlepsza zdecydowanie latem, gdy mamy wysyp dojrzałych w słońcu warzyw. Nic nie zastąpi pomidorówki ze świeżych ...

Najlepsza na świecie zupa pomidorowa tradycyjny przepis...: Zupa Pomidorowa is a beloved Polish tomato soup made from scratch using homemade rosół, tomato paste, and sour cream. This creamy and comfor...

W organizmie działa jak odkurzacz! Ta zupa to bomba zdrowia: W organizmie działa jak odkurzacz! Ta zupa to bomba zdrowia Zupa pomidorowa to zdrowa i smaczna opcja dla odżywiających się zdrowoSpożywani...

Zupa pomidorowa z tym dodatkiem smakuje jak u babci.: Zupa pomidorowa Źródło: Shutterstock / GreenArt. Czy można ulepszyć smak klasycznej zupy pomidorowej , która od lat króluje na polskich stołach? O...

Najlepsza na świecie zupa pomidorowa - DoradcaSmaku.pl: Przepis i sposób przygotowania na : Najlepsza na świecie zupa pomidorowa .W trakcie gotowania dodać koncentrat pomidorowy . Do ugotowanej zupy d...

Przykłady zastosowań- zdania prawdziwe

AI FACT-CHECKER

PRAWDA

ANALIZOWANE WEJŚCIE

"2 + 2 = 4"

1. Wstępna analiza: The mathematical equation "2 + 2 = 4" is universally accepted as true within standard arithmetic and does not conflict with any of the provided factual statements. It is a basic, verifiable truth independent of the contextual facts listed.

2. Werdykt po krytyce: The equation 2 + 2 = 4 is a basic arithmetic truth that holds in standard mathematics and is not contradicted by any of the provided evidence. The cited sources discuss unrelated topics such as military units, properties of powers of two, divergent series, or algebraic expressions involving negative signs; none of them challenge the validity of the simple addition statement.

Wiarygodność Cytowań (XAI): 0%

PL **PODSUMOWANIE**

Twierdzenie 2 + 2 = 4 jest prawdziwe w standardowej arytmetyce. Żadne z podanych dowodów nie kwestionuje tej równości, ponieważ odnoszą się do innych zagadnień matematycznych lub historycznych. Dlatego ostateczny werdykt to Prawda.

DOWODY (LIVE SEARCH):

224 Batalion WOP: 224 Batalion Wojsk Ochrony Pogranicza – nieistniejący obecnie samodzielny pododdział Wojsk Ochrony Pogranicza....

Power of two - Wikipedia: December 12, 2025 - Book IX, Proposition 36 of Elements proves that if the sum of the first n terms of this progression is a prime number (and thus is a Mersenne prime as men...

1 + 2 + 3 + 4 + ⋯: The infinite series \(1 + 2 + 3 + 4 + \cdots\), often called the sum of the natural numbers, diverges to positive infinity when summed in the conventional partial sum sense, as the....

Evaluate (-4)^2 | Mathway: Free math problem solver answers your algebra, geometry, trigonometry, calculus, and statistics homework questions with step-by-step explanations, just like a math tutor....

r/learnmath on Reddit: -2^2 = -4 how?: ...

AI FACT-CHECKER

PRAWDA

ANALIZOWANE WEJŚCIE

"Portugalia wygrała mistrzostwa Europy w 2016"

1. Wstępna analiza: Z podanych faktów wynika, że reprezentacja Portugalii wygrała Mistrzostwa Europy w Piłce Nożnej (Euro) w 2016 roku, pokonując Francję.

2. Werdykt po krytyce: Reprezentacja Portugalii wygrała finał Mistrzostw Europy w Piłce Nożnej 2016, pokonując Francję 1:0 po dogrywce (gola Édera). Wszystkie podane dowody potwierdzają ten wynik.

Wiarygodność Cytowań (XAI): 100%

PL **PODSUMOWANIE**

Portugalia zdobyła tytuł mistrza Europy w 2016 roku, zwyciężając Francję w finale po dogrywce. Gole strzelono przez Édera w 109. minucie meczu. Mistrzostwo to było pierwsze w historii tej reprezentacji.

DOWODY (LIVE SEARCH):

Mistrzostwa Europy w Piłce Nożnej 2016/Finał: Finał Mistrzostw Europy w Piłce Nożnej 2016 (ostatni, 51. mecz) odbył się w niedzielę 10 lipca 2016 o godzinie 21:00 na Stade de France w Saint-Denis we F...

Portugalia mistrzem Europy! To podopieczni Santosa wyeliminowali Polskę ...: Reprezentacja Portugalii w finale mistrzostw Europy 2016 na Stade de France w Saint-Denis pokonała po dogrywce 1:0 gospodar...

Euro 2016: Portugalia mistrzem Europy, ale nie ona ma najlepszy bilans ...: Portugalia świętuje mistrzostwo Europy , ale pod względem całościowego bilansu lepsza okazała się Francja. Wysoko w zbiorcze...

Euro 2016. Finał Portugalia - Francja. Pepe zwymiotował po końcowym gwizdku: Portugalia wygrała po golu rezerwowego Edera ze 109. min. Na początku spotkania, po ostrym wejściu Payeta, boisko musiał op...

Euro 2016: historia mistrzostw Europy. Triumf Portugalii, Polacy w ...: Euro 2016 było najbardziej udanymi mistrzostwami Europy w historii dla reprezentacji Polski. Drużyna Adama Nawałki dotarła aż do...

Przykłady zastosowań- źle sformułowane prompty

AI FACT-CHECKER

ODRZUCONO

ANALIZOWANE WEJŚCIE

"Ile waży Słońce?"

⚠️ The sentence is an interrogative asking for information, not a declarative statement.

Ewaluacja

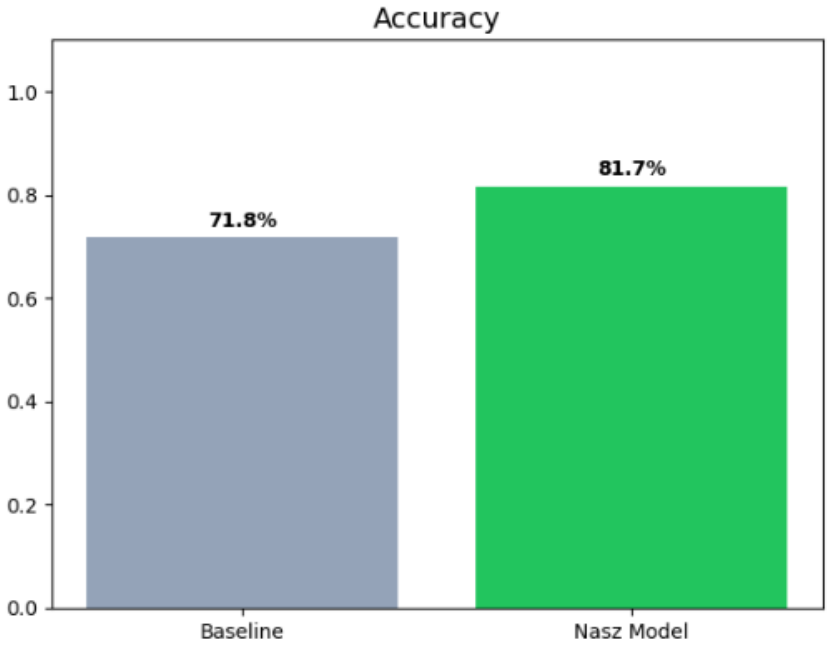
Accuracy
1.0
0.8
0.6
0.4
0.2
0.0
71.8%
81.7%
Baseline
Nasz Model

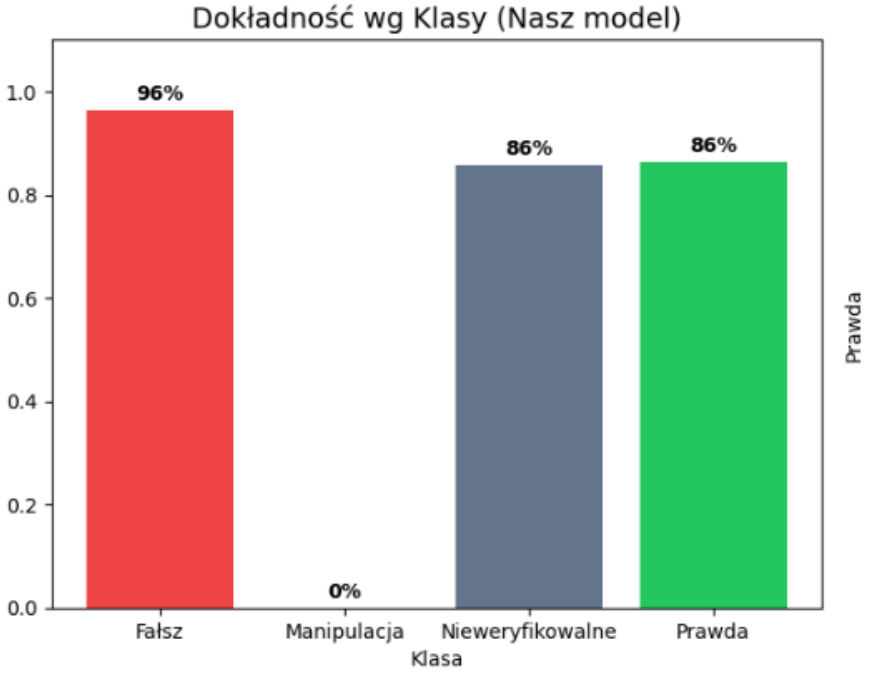
Dokładność wg Klasy (Nasz model)
1.0
0.8
0.6
0.4
0.2
0.0
96%
0%
86%
86%
Fałsz
Manipulacja
Nieweryfikowalne
Prawda
Klasa
Prawda

Ewaluacja

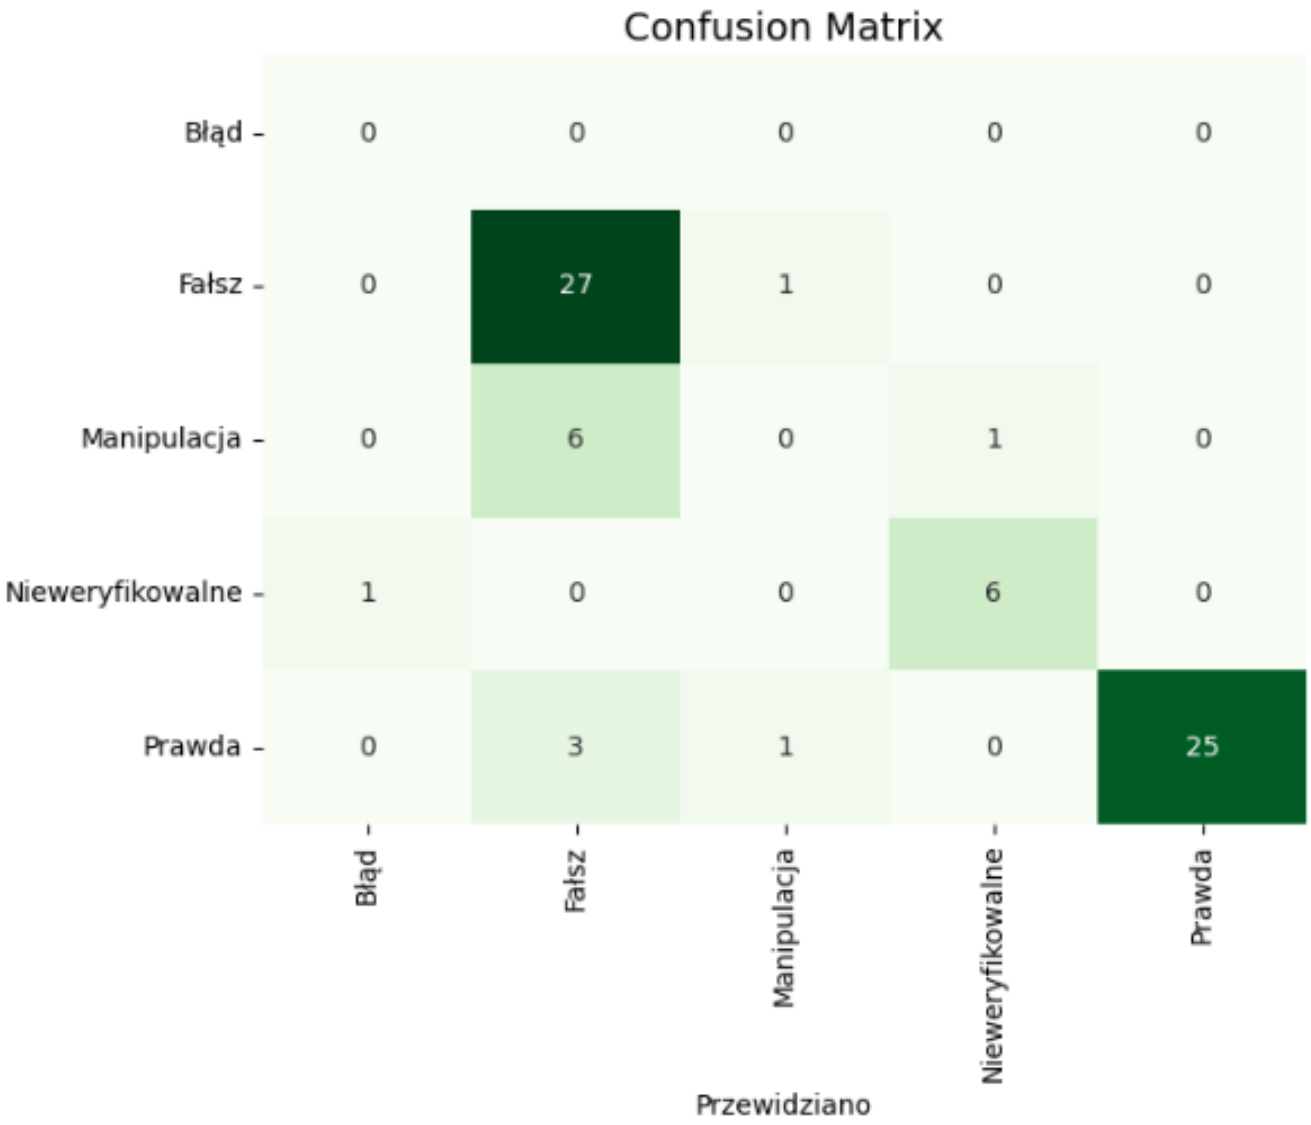
Confusion Matrix
Błąd
Fałsz
Manipulacja
Nieweryfikowalne
Prawda
0 0 0 0 0
0 27 1 0 0
0 6 0 1 0
1 0 0 6 0
0 3 1 0 25
Błąd
Fałsz
Manipulacja
Nieweryfikowalne
Prawda
Przewidziano

Wnioski

- LLM mogą skutecznie wspierać fact-checking
- Wyjaśnialność zwiększa zaufanie do systemu
- Model przewyższa prosty baseline
- Klasa manipulacji wymaga dalszych badań