Projekt 2 – Wyjaśnialne systemy oparte na LLM

Temat 13: Wyjaśnialny detektor fake newsów z użyciem LLM

Karolina Gralak, Wiktor Chmiel

2025

1 Wstęp

Dynamiczny rozwój dużych modeli językowych (LLM) umożliwia ich zastosowanie nie tylko w generowaniu tekstu, ale również w zadaniach analitycznych, takich jak weryfikacja informacji czy detekcja fake newsów. Jednym z kluczowych wyzwań w tym obszarze jest nie tylko poprawność odpowiedzi modelu, lecz także jej **wyjaśnialność** (XAI), czyli zdolność do uzasadnienia podjętej decyzji.
Celem naszego projektu było zaprojektowanie i zaimplementowanie wyjaśnialnego systemu fact-checkingowego opartego na LLM, który klasyfikuje krótkie twierdzenia jako: *Prawda*, *Fałsz*, *Manipulacja* lub *Nieweryfikowalne*, a następnie prezentuje użytkownikowi uzasadnienie decyzji wraz z cytowanymi dowodami.

2 Opis zadania

Zadanie polegało na:

- przygotowaniu zbioru twierdzeń testowych wraz z ręcznymi etykietami,
- zbudowaniu pipeline'u z wykorzystaniem lokalnego modelu LLM,
- przeprowadzeniu automatycznej ewaluacji jakości klasyfikacji,
- dodaniu warstwy wyjaśnialności (XAI),
- przygotowaniu demonstracji działania systemu.

3 Baza wiedzy i dane testowe

Zastosowano lokalną bazę wiedzy zawierającą fakty z różnych domen, m.in.:

- Gospodarka,
- Polityka/ Historia,
- Sport,
- Youtube/ Technologia,
- Nauka/ Zdrowie,
- Jedzenie i inne

Na jej podstawie przygotowano zbiór testowy składający się z 50 twierdzeń, z ręcznie przypisanymi etykietami. Dane obejmowały zarówno twierdzenia prawdziwe, jak i fałszywe, manipulacyjne oraz nieweryfikowalne.

4 Działanie systemu i pipeline modelu

Zaimplementowany system weryfikacji informacji opiera się na wieloetapowym pipeline'ie wykorzystującym duży model językowy (LLM). Jego celem jest nie tylko klasyfikacja twierdzeń, ale również zapewnienie wyjaśnialności podejmowanych decyzji.
Proces analizy pojedynczego twierdzenia przebiega w kilku krokach, z których każdy realizowany jest przez osobną funkcję w kodzie.

4.1 Walidacja intencji

Pierwszym etapem jest sprawdzenie, czy analizowany tekst jest rzeczywiście twierdzeniem, które można zweryfikować. Odpowiada za to funkcja `validate_intent`. Model ocenia, czy wejście stanowi zdanie oznajmujące lub pytanie weryfikujące. W przypadku tekstów niebędących twierdzeniami (np. poleceń lub opinii), system może je odrzucić jeszcze przed dalszą analizą.

4.2 Pobieranie kontekstu i dowodów

Następnie system przygotowuje kontekst potrzebny do weryfikacji. Wykorzystywane są dwa źródła informacji:

- lokalna baza wiedzy zawierająca wcześniej zdefiniowane fakty,
- zewnętrzne wyszukiwanie informacji z wykorzystaniem biblioteki DuckDuckGo Search (DDGS).

Zgromadzone dowody są przekazywane do modelu w postaci tekstowej jako kontekst do dalszej analizy. Dzięki temu model nie opiera się wyłącznie na swojej wiedzy wbudowanej, lecz odnosi się do konkretnych źródeł.

4.3 Wstępna klasyfikacja (Draft)

Kolejnym krokiem jest wstępna analiza twierdzenia, realizowana w funkcji odpowiedzialnej za tzw. *draft*. Model otrzymuje twierdzenie wraz z kontekstem i generuje początkowy werdykt (np. Prawda, Fałsz lub Manipulacja) oraz krótkie uzasadnienie. Ten etap można traktować jako pierwszą, roboczą ocenę.

4.4 Krytyczna weryfikacja werdyktu

Na podstawie wyniku wstępnego model przeprowadza kolejną analizę, której celem jest krytyczna ocena wcześniejszego werdyktu. W tym etapie model:

- ponownie analizuje dowody,
- koryguje ewentualne błędy wstępnej oceny,
- generuje końcowy werdykt oraz uzasadnienie w języku naturalnym,
- wybiera fragmenty tekstu pełniące rolę cytowanych dowodów.

Wynik tego etapu stanowi ostateczną decyzję systemu.

4.5 Weryfikacja cytowań (Grounding)

Aby ograniczyć halucynacje modelu, zastosowano dodatkowy mechanizm weryfikacji cytatów, zaimplementowany w funkcji `verify_grounding`. Sprawdza ona, czy cytaty wskazane przez model są faktycznie zgodne z dostępnymi dowodami.

4.6 Obsługa błędów i odporność systemu

Komunikacja z modelem realizowana jest za pomocą funkcji `get_completion`, która pełni rolę warstwy pośredniej. Funkcja ta:

- wysyła zapytanie do modelu,
- wymusza odpowiedź w formacie JSON,
- obsługuje błędy generacji i parsowania,
- zapobiega przerwaniu działania systemu w przypadku niepoprawnej odpowiedzi.

Dzięki temu pipeline pozostaje stabilny nawet przy nieprzewidywalnych zachowaniach modelu językowego.

5 Wizualizacja wyników i wyjaśnialność

Istotnym elementem projektu jest czytelna prezentacja wyników działania systemu. W tym celu zaprojektowano warstwę wizualizacyjną opartą na generowaniu dynamicznych kart wyników w formacie HTML.
Każdy wynik weryfikacji prezentowany jest użytkownikowi w postaci karty zawierającej:

- analizowane twierdzenie,
- końcowy werdykt modelu,
- uzasadnienie decyzji,
- cytowane dowody,
- wskaźnik wiarygodności cytowań (grounding score),
- porównanie werdyktu modelu z ręczną etykietą.

Kolorystyka oraz ikony wizualne są uzależnione od rodzaju werdyktu (Prawda, Fałsz, Manipulacja, Nieweryfikowalne), co ułatwia szybkie zrozumienie wyniku analizy.
Jednym z głównych założeń projektu było zapewnienie wyjaśnialności decyzji podejmowanych przez model językowy. W kontekście systemów opartych na LLM jest to szczególnie istotne, ponieważ modele te mają tendencję do generowania odpowiedzi pozbawionych jawnego uzasadnienia lub opartych na halucynacjach.
Zaimplementowany system realizuje wyjaśnialność na kilku poziomach.

Wyjaśnialność werdyktu

Każdy werdykt generowany przez model (Prawda, Fałsz, Manipulacja lub Nieweryfikowalne) jest opatrzony opisowym uzasadnieniem w języku naturalnym. Użytkownik otrzymuje nie tylko wynik klasyfikacji, lecz także informację, dlaczego model podjął taką decyzję. Pozwala to zrozumieć logikę działania systemu oraz ocenić sensowność argumentacji.

Cytowanie dowodów

System wymaga od modelu wskazania fragmentów tekstu, które stanowią podstawę wydanego werdyktu. Cytaty te pochodzą z lokalnej bazy wiedzy lub zewnętrznych źródeł wyszukanych w Internecie. Dzięki temu użytkownik może samodzielnie zweryfikować, na jakich informacjach opiera się model.

Weryfikacja cytowań (Grounding)

Aby ograniczyć ryzyko halucynacji, wprowadzono mechanizm automatycznej weryfikacji cytowań. Funkcja odpowiedzialna za grounding porównuje cytaty wygenerowane przez model z rzeczywistymi dowodami, obliczając wskaźnik zgodności. Wysoki *grounding score* oznacza, że argumentacja modelu jest dobrze osadzona w dostępnych danych, natomiast niski wynik sygnalizuje potencjalne problemy z wiarygodnością.

Porównanie z etykietą ręczną

Dodatkowym elementem wyjaśnialności jest możliwość porównania decyzji modelu z ręcznie przypisaną etykietą (ground truth). System wizualnie informuje użytkownika o zgodności lub rozbieżności tych dwóch ocen. Takie podejście ułatwia analizę błędów modelu oraz zwiększa transparentność procesu decyzyjnego.

Wyjaśnialność procesu

Wyjaśnialność systemu nie ogranicza się wyłącznie do wyniku końcowego. Dzięki podziałowi analizy na etapy (walidacja intencji, wstępna analiza, krytyczna weryfikacja, grounding), użytkownik może prześledzić cały proces decyzyjny modelu krok po kroku. Pozwala to lepiej zrozumieć, w którym momencie mogło dojść do błędnej interpretacji twierdzenia.

Znaczenie XAI w detekcji fake newsów

Zastosowane mechanizmy wyjaśnialności są szczególnie istotne w kontekście detekcji fake newsów, gdzie sama klasyfikacja nie jest wystarczająca. Użytkownik musi mieć możliwość oceny wiarygodności systemu oraz zrozumienia przyczyn podjętej decyzji. Dzięki połączeniu werdyktu, uzasadnienia, cytatów oraz ich weryfikacji, zaprojektowany system spełnia podstawowe założenia wyjaśnialnej sztucznej inteligencji.

6 Analiza przypadków, przykłady zastosowań

Zaobserwowano, że system poprawnie identyfikuje twierdzenia:

6.1 Sprzeczne z bazą wiedzy (Fałsz)

AI FACT-CHECKER ✕ **FAŁSZ**

ANALIZOWANE WEJŚCIE

"Unia Europejska nakazała konfiskatę wszystkich samochodów spalinowych w Polsce do końca tego roku, bo wszedł zakaz na takowe pokjazdy"

1. Wstępna analiza: Z podanych faktów nie wynika, że Unia Europejska nakazała konfiskatę wszystkich samochodów spalinowych w Polsce ani wprowadziła zakaz ich użytkowania do końca roku. Nie ma żadnego wymienionego aktu prawnego lub dyrektywy UE dotyczącej takiego zakazu. Dlatego twierdzenie jest nieprawdziwe.

2. Werdykt po krytyce: The provided evidence shows that the European Union has not imposed a confiscation of all combustion-engine cars in Poland nor banned their use until the end of this year. The EU's policy focuses on phasing out new sales of combustion vehicles after 2035 and reducing CO2 emissions, but it explicitly allows existing vehicles to continue operating. No legal act or directive mandates confiscation or an immediate ban in Poland.

Wiarygodność Cytowań (XAI): 0%

PL **PODSUMOWANIE**

Unia Europejska nie nakazała konfiskaty wszystkich samochodów spalinowych w Polsce ani zakazu ich użytkowania do końca roku; istniejące pojazdy mogą nadal być używane, a regulacje dotyczą jedynie nowych sprzedaży po 2035 r.

DOWODY (LIVE SEARCH):

Komisja Europejska rezygnuje z zakazu aut spalinowych po 2035 roku: December 18, 2025 - Komisja Europejska wycofuje się z planu całkowitego zakazu sprzedaży nowych samochodów spalinowych w Unii Europe...

Unijny zakaz sprzedaży nowych samochodów spalinowych od 2035 r. - co to oznacza? | Tematy | Parlament Europejski: March 7, 2023 - Tak, nadal będzie można jeździć obecnymi samochodami. Nowe przepisy ni...

Komisja Europejska podjęła ważną decyzję dla całej motoryzacji. Co to oznacza dla klientów?: December 17, 2025 - Kiedy w marcu 2023 r. zapadła decyzja o zakazie sprzedaży aut spalinowych na terenie UE...

Unia wycofa się z zakazu aut spalinowych od 2035? Urzędnik KE nie ma wątpliwości: September 28, 2024 - Transport stał się ofiarą własnego sukcesu - stwierdził Eddy Liegeois z Komisji Europejskiej. Pod...

Koniec Aut Spalinowych. Od Kiedy Zakaz Sprzedaży? - Elektromobilni.pl: January 24, 2024 - Unia Europejska zobowiązała się do przedstawienia w 2026 roku raportu dotyczącego wprowadzonych przepisów....

6.2 Prawdziwe

AI FACT-CHECKER ✅ **PRAWDA**

ANALIZOWANE WEJŚCIE

"2 + 2 = 4"

1. Wstępna analiza: The mathematical equation "2 + 2 = 4" is universally accepted as true within standard arithmetic and does not conflict with any of the provided factual statements. It is a basic, verifiable truth independent of the contextual facts listed.

2. Werdykt po krytyce: The equation 2 + 2 = 4 is a basic arithmetic truth that holds in standard mathematics and is not contradicted by any of the provided evidence. The cited sources discuss unrelated topics such as military units, properties of powers of two, divergent series, or algebraic expressions involving negative signs; none of them challenge the validity of the simple addition statement.

Wiarygodność Cytowań (XAI): 0%

PL **PODSUMOWANIE**

Twierdzenie 2 + 2 = 4 jest prawdziwe w standardowej arytmetyce. Żadne z podanych dowodów nie kwestionuje tej równości, ponieważ odnoszą się do innych zagadnień matematycznych lub historycznych. Dlatego ostateczny werdykt to Prawda.

DOWODY (LIVE SEARCH):

224 Batalion WOP: 224 Batalion Wojsk Ochrony Pogranicza – nieistniejący obecnie samodzielny pododdział Wojsk Ochrony Pogranicza....

Power of two - Wikipedia: December 12, 2025 - Book IX, Proposition 36 of Elements proves that if the sum of the first n terms of this progression is a prime number (and thus is a Mersenne prime as men...

1 + 2 + 3 + 4 + ⋯: The infinite series \(1 + 2 + 3 + 4 + \cdots\), often called the sum of the natural numbers, diverges to positive infinity when summed in the conventional partial sum sense, as the....

Evaluate (-4)^2 | Mathway: Free math problem solver answers your algebra, geometry, trigonometry, calculus, and statistics homework questions with step-by-step explanations, just like a math tutor....

r/learnmath on Reddit: -2^2 = -4 how?: ...

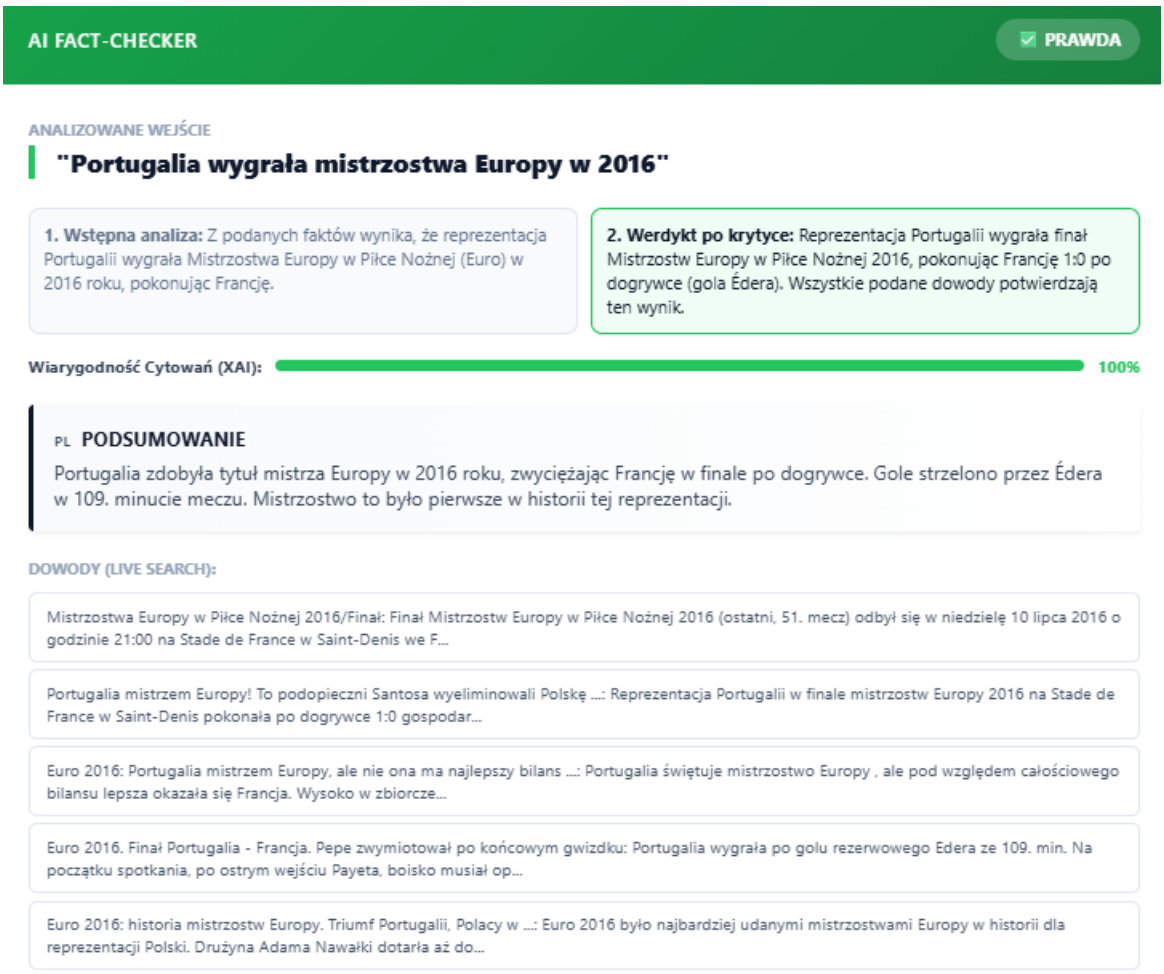

6.3 Źle sformułowane prompty (różne od stwierdzeń)

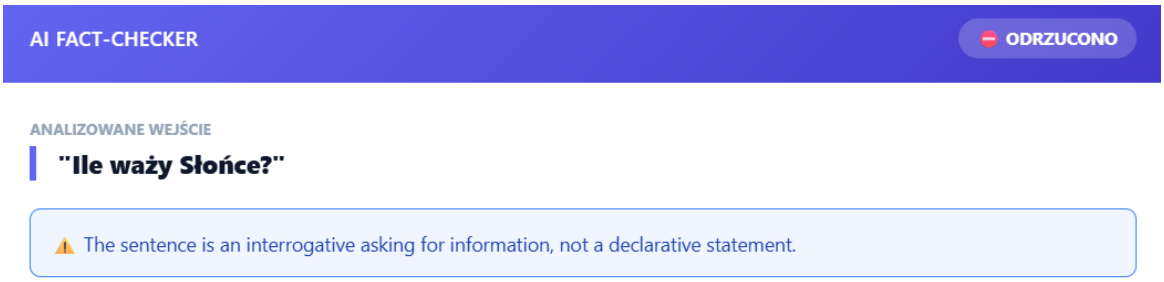

6.4 Pozbawione danych (Nieweryfikowalne)

AI FACT-CHECKER ❓ NIEWERYFIKOWALNE

ANALIZOWANE WEJŚCIE

"W 2040 roku prezydentem Polski zostanie kobieta o imieniu Anna."

1. Wstępna analiza: Brak informacji w podanej bazie wiedzy dotyczącej przyszłych wyborów prezydenckich ani o osobach, które mogłyby objąć urząd w 2040 roku. Stwierdzenie dotyczy zdarzenia z przyszłości i nie można go potwierdzić ani obalić na podstawie dostępnych faktów.

2. Werdykt po krytyce: The claim concerns a future political event (the presidency of Poland in 2040) and there is no verifiable evidence or reliable source confirming that a woman named Anna will hold the office at that time. The provided references discuss individuals named Anna, a person called Mata expressing ambitions for the presidency, and general information about names, but none provide factual confirmation of an election outcome in 2040. Therefore the statement cannot be verified as true or false based on current knowledge.

Wiarygodność Cytowań (XAI): 100%

PL **PODSUMOWANIE**

Twierdzenie dotyczy przyszłego wydarzenia politycznego i nie ma dostępnych wiarygodnych dowodów potwierdzających lub obalających, że w 2040 roku prezydentem Polski będzie kobieta o imieniu Anna. Stąd jest nieweryfikowalne.

DOWODY (LIVE SEARCH):

Znaczenie imienia Anna . Skąd pochodzi, kiedy są... | Strona Kobiet: Znaczenie imienia Anna może wiele powiedzieć o osobach, które tak nazwano. Przede wszystkim są to kobiety inteligentne, empatyczne ...

2040 Mata Tekst | TikTok: Mata chce zostać Prezydentem Polski w 2040 roku . #mata #michałmatczak #michałmatamatczak #420 #fundacja420 #mata 2040 # prezydent # polska . Prezydent Mata o "imprezie masow...

Anna , która bada Bałtyk: Anna , która bada Bałtyk. poniedziałek, 17 kwietnia 2023. Informacja prasowa/Equinor.pl.- Badania wietrzności to ważny krok w realizacji morskiej farmy wiatrowej Bałtyk I, kt...

Mata chce zostać prezydentem ? "Nie do wiary, że ludzie tak na serio..."...: - Oficjalnie rozpoczynam moją kampanię na urząd prezydenta Rzeczpospolitej Polskiej w 2040 r. - zapowiedział w najnowszym n...

Kim jest Anna ? Dowiedz się o niej więcej! - Prezydent internetu: Kobieta : Anna jest kobietą o imieniu Anna . Anna jest osobą, która od najmłodszych lat wykazywała się niezwykłą determinacją i pasją ...

Oraz inny przykład związany z własną opinią

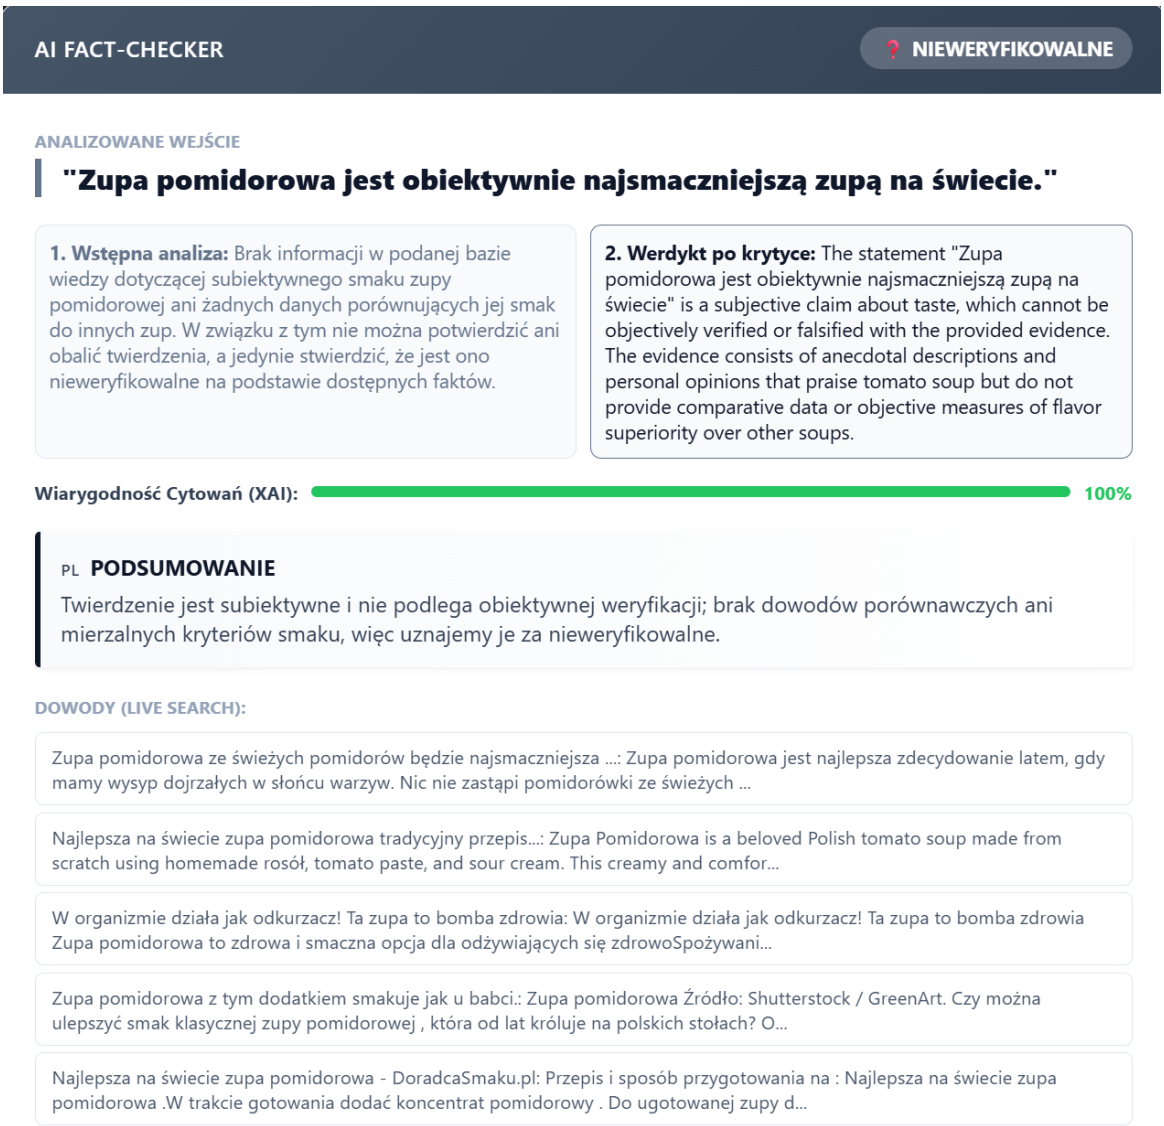

7 Ewaluacja

Do oceny jakości systemu wykorzystano metrykę **accuracy**, definiowaną jako stosunek liczby poprawnie sklasyfikowanych twierdzeń do liczby wszystkich przykładów testowych.
Jako punkt odniesienia zastosowano prosty baseline polegający na zawsze przewidywaniu najczęściej występującej klasy w zbiorze danych. Uzyskana dokładność bazowa wyniosła 71.8%. Zaproponowany system oparty na LLM osiągnął wyższą skuteczność (81.7%), co potwierdza, że model uczy się rozróżniać poszczególne klasy, a nie jedynie zgaduje dominującą etykietę.

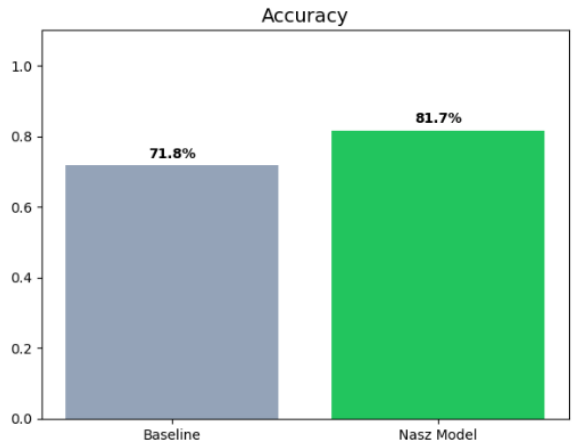

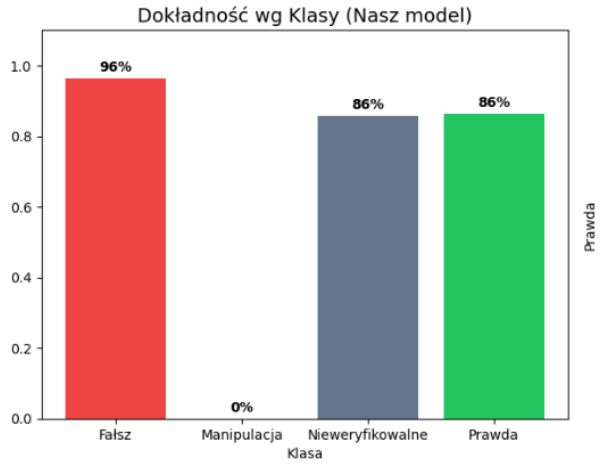

Dodatkowo przeanalizowano wyniki klasyfikacji za pomocą macierzy pomyłek (confusion matrix), która pozwala szczegółowo ocenić, w jaki sposób model klasyfikuje poszczególne kategorie oraz jakie typy błędów popełnia najczęściej.

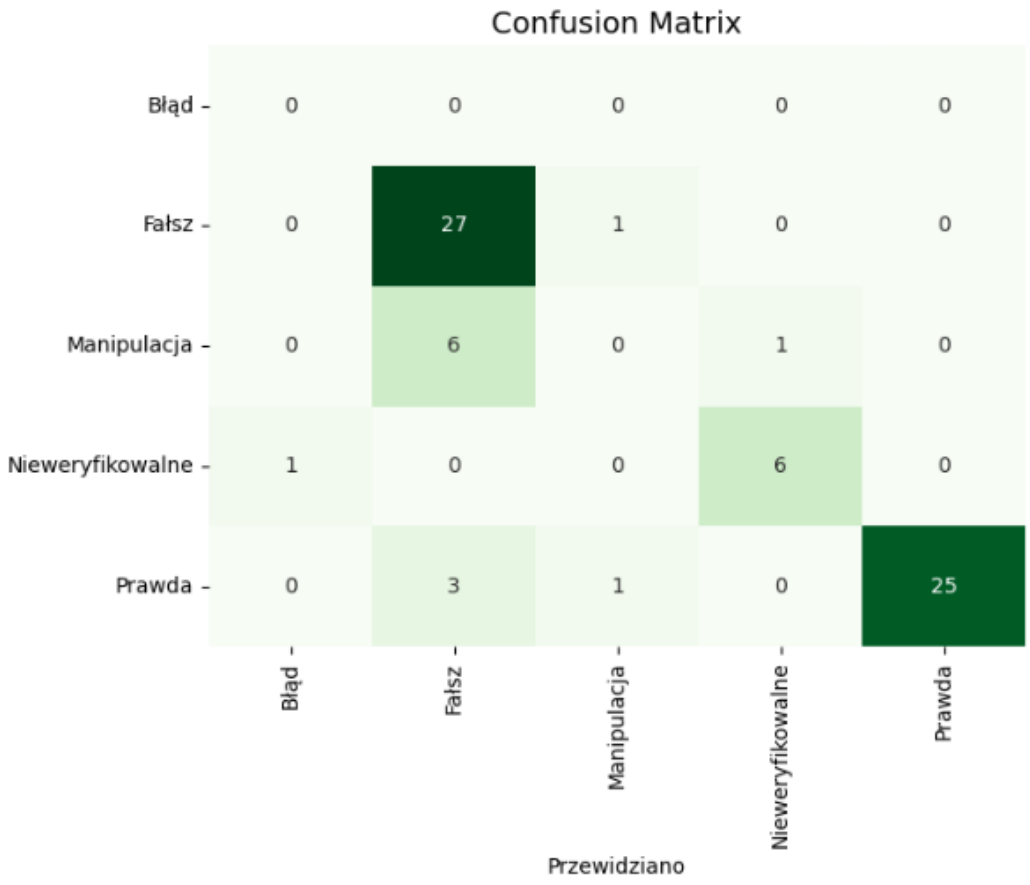

W celu dokładniejszej oceny jakości działania zaproponowanego systemu, poza ogólną dokładnością (accuracy), wykorzystano standardowe metryki stosowane w zadaniach klasyfikacji wieloklasowej: precision, recall oraz F1-score. Pozwalają one na bardziej szczegółową analizę zachowania modelu dla poszczególnych klas, zwłaszcza w przypadku niezbalansowanego zbioru danych.

Klasa	**Precision**	**Recall**	**F1-score**	**Support**
Błąd	0.00	0.00	0.00	0
Fałsz	0.75	0.96	0.84	28
Manipulacja	0.00	0.00	0.00	7
Nieweryfikowalne	0.86	0.86	0.86	7
Prawda	1.00	0.86	0.93	29
Accuracy		0.82		
Macro avg	0.52	0.54	0.53	71
Weighted avg	0.79	0.82	0.80	71

Analiza metryk pokazuje, że model osiąga wysoką skuteczność w rozpoznawaniu klas „Prawda” oraz „Fałsz”, natomiast największe trudności sprawia mu poprawna identyfikacja klasy „Manipulacja”. Jest to zgodne z obserwacjami z macierzy pomyłek oraz wynika z niejednoznacznego charakteru tej kategorii.
Średni wskaźnik wyjaśnialności (XAI) wyniósł 77.7%, co wskazuje, że większość cytatów generowanych przez model była dobrze ugruntowana w dostępnych dowodach.

8 Wnioski

Przeprowadzone eksperymenty pokazują, że modele językowe mogą być skutecznie wykorzystywane do zadań weryfikacji informacji, nawet bez klasycznego uczenia nadzorowanego. Zaproponowany system osiąga wyraźnie lepsze wyniki niż prosty model bazowy, jednocześnie oferując użytkownikowi szczegółowe uzasadnienie podejmowanych decyzji. Największym wyzwaniem pozostaje poprawna identyfikacja treści manipulacyjnych, co wskazuje na potrzebę dalszych badań nad bardziej precyzyjnym rozróżnianiem półprawd i treści wyrwanych z kontekstu.